

- 领域认知缺口（思维层面）
- 架构设计缺口（工程思维层面）
- 工程实践缺口（执行层面）
- 20250926

领域认知缺口（思维层面）

- 数据治理不等于把生成标准格式数据
- 数据治理=控制+透明+责任
- 缺少关键认知

我认为的治理	实际医疗数据治理要求
输出符合CDSIC的csv文件	输出 + 血缘图谱 + 质量报告 + 敏感字段清单
配置写全了就安全	配置本身需版本控制、审批、变更审计
数据来自医保所以安全	必须主动验证并记录数据敏感级别

- 提升建议
 - 精读《医疗卫生机构数据安全管理办法》《个人信息保护法》第 73 条（匿名化定义）
 - 研究 FDA 对临床数据提交的审计要求（如 21 CFR Part 11）
 - 学习 DAMA-DMBOK 中“数据治理”“数据质量”“元数据管理”章节
 - 元数据管理相关笔记，请参阅[元数据管理](#)

架构设计缺口（工程思维层面）

- 治理型架构的核心特征
 - 可观测性： 每一步操作可记录、可查询
 - 不可变性： 输出结果附带输入快照（如配置哈希）
 - 策略驱动： 脱敏规则、质量规则、访问规则外置为策略，而非硬编码

场景	我目前当前做法	治理性做法
字段处理	直接清洗输出	先识别敏感级别 → 应用脱敏策略 → 记录处理日志

场景	我目前当前做法	治理性做法
任务执行	打印"处理完成"	生成任务元数据（谁、何时、用何配置、输入/输出结果）
错误处理	返回空 DataFrame	抛出结构化异常（含数据集、字段、错误类型），供监控系统捕获

- 提升建议
 - 学习Policy Pattern(策略模式)：将合规规则抽象为可插拔策略**
 - 研究OpenLineage、 Marquez等开源血缘框架的设计**
 - 在现有代码中尝试添加 AuditLogger 模块，记录关键操作**

工程实践缺口（执行层面）

- 医疗数据工程的工程底线
 - 必须由测试：核心逻辑100%覆盖；
 - 必须可复现：任务输出=f(输入数据+配置+代码版本)；
 - 必须可隔离：多项目并发无干扰
- 目前缺失的实践
 - 单元测试
 - 配置校验
 - 工作空间隔离
 - 安全输入处理
- 提升建议
 - 为 DM 类补全 pytest 测试（从 _map_sex 开始）；
 - 在 ConfigurationService 中增加配置 schema 校验；
 - 引入 click 或 typer 替代 argparse，支持工作空间参数。

20250926

能力维度	当前状态	提升路径
领域认知	严重不足	学法规 + 看监管案例
治理架构	初步意识	学策略模式 + 血缘设计
工程实践	可快速补足	补测试 + 加隔离 + 做校验