

- 医疗数据治理岗位百问百答 (V1.0)
 - 一、领域认知类
 - Q1: 数据治理的本质是什么? 和生成标准格式数据有什么区别?
 - Q2: 为什么“数据来自医保所以安全”是错误认知?
 - Q3: 医疗数据治理的核心交付物有哪些? 为什么需要它们?
 - Q4: 为什么质量报告中还会存在“死亡日期 < 确诊日期”这类逻辑错误? 为什么不直接剔除? 已知数据缺口为何不“修复”?
 - 一、为什么会出现“死亡日期 < 确诊日期”?
 - 二、为什么不直接剔除这些记录?
 - 三、已知数据缺口为何不“处理”(如插值、填充)?
 - 四、如何向客户解释这种“不完美”?
 - Q5: 如何理解一个“高质量的数据”?
 - 一、传统误区: 高质量 $\neq$ “100% 准确 + 无缺失”
 - 二、医疗数据的高质量 = “四可”原则
 - 三、高质量数据的三大标志 (医疗场景)
 - 四、高质量 vs 低质量: 一个对比
 - 五、总结: 高质量数据的本质
 - 二、合规与法规类
 - Q1: 在中国, 医疗数据项目应依据哪些法规?
 - Q2: 如何判断一个字段是否敏感?
 - 三、治理实践类
 - Q1: 你在 DWS 层 (专病库) 具体做什么治理工作?
 - Q2: 如何保证 DWS 层数据质量?
 - 四、面试表达类
 - Q1: 如何一句话介绍你的数据治理经验?
 - Q2: 什么是专病库数据建模?
 - Q3: 专病库设计思路
 - 1、项目需求:
 - 2、数据域设计
 - 3、字段设计
 - 4、源数据探查
 - 5、映射规则设计
 - 6、字典设计
 - 7、程序实现
 - Q4: 采用的是架构
 - Q5: 为什么要设计专病库
 - Q6: 为什么要这样设计专病库

- Q7: 这样设计的目的
- Q8: 专病库的价值
- Q9: 专病库的意义
- Q10: 专病库的设计方法
- Q11: 你在这个里面担任什么角色
- Q12: 遇到过印象最深的问题是什么?如何处理的
- Q13: 目前项目还可以优化的点
- Q14: 你从过往的工作中可以迁移的能力
- Q9: 被问“数据分析有哪些阶段”时如何回答?
- Q10: 如何回答“你用什么技术栈”?
- 五、待补充问题（持续更新）
- 术语表
 - 血缘图谱（Data Lineage）{#术语表-血缘图谱}
 - 1. 定义
 - 2. 可视化形式（可选）
 - 3. 文档关键要素（必须包含）
 - 4. 典型用途
 - 有向无环图DAG (Directed Acyclic Graph) {#术语表-有向无环图DAG}
 - 1. 定义
 - 2. 为什么血缘图谱要用 DAG?
 - 3. DAG 在血缘图谱中的典型表现
 - 溯源 {#术语表-溯源}
 - 📍 Situation（背景）
 - 🎯 Task（任务）
 - 🛠️ Action（行动）
 - ✅ Result（结果）
 - 质量报告 {#术语表-质量报告}
 - 一、质量报告的核心内容（以 DWS 专病库为例）
 - 二、敏感字段清单：包含哪些？为什么敏感？
 - 三、敏感字段的处理策略（DWS 层）
 - 四、为什么这样处理？
 - 可控 {#术语表-可控}
 - 什么是“可控”？如何保证行为可控？有什么方法论？
 - 入组逻辑 {#术语表-入组逻辑}
 - 入组逻辑如何设定？
 - 指标口径 {#术语表-指标口径}
 - 指标口径如何调整？
 - 数据可行性 {#术语表-数据可行性}

- 如何保证数据可行性？
 - 1. 前置评估：摸清数据“家底”
 - 2. 设计“最小可行证据链”
 - 3. 制定兜底与降级策略
 - 4. 持续验证可行性
 - 总结：数据可行性的核心思维
- 专病库数据建模 {#术语表-专病库数据建模}
- 质量管控 {#术语表-质量管控}
- 商业化分析 {#术语表-商业化分析}
- 结构化思考框架 {#术语表-结构化思考框架}
 - 1、底层方法论: 三层穿透模型(What → Why → How)
 - 2、进阶工具：STAR-V 模型（用于回答“经历类”问题）

医疗数据治理岗位百问百答（V1.0）

定位：面向医疗健康领域数据治理、专病库建设、医保数据商业化岗位的实战问答手册 **原则：**问题来自真实面试/项目痛点，答案简洁、合规、可复用 **更新记录：**2025-09-29 初版（基于与 AI 的诊断对话）

一、领域认知类

Q1：数据治理的本质是什么？和生成标准格式数据有什么区别？

A：数据治理 ≠ 输出 CSV 或 JSON。其本质是 “**控制 + 透明 + 责任**”：

- **控制：**通过策略约束数据使用（如“专病库不得输出未脱敏身份证”）；
- **透明：**所有操作可记录、可查询（如任务日志、[血缘图谱](#)）；
- **责任：**问题可 [溯源](#)、权责可归属（如 DWS 层质量问题由我方负责）。

✅ 关键：治理是**管理行为**，不是**技术动作**。

Q2：为什么“数据来自医保所以安全”是错误认知？

A: 即使数据由医保局提供, 我方作为**数据处理者** (《个人信息保护法》第 21 条), 仍有法定义务:

- 识别敏感个人信息 (如身份证号、诊断编码);
- 采取去标识化措施;
- 记录处理活动。

 错误引用 HIPAA (美国法律)!  正确依据: 《个人信息保护法》《数据安全法》《医疗卫生机构数据安全管理办法》。

Q3: 医疗数据治理的核心交付物有哪些? 为什么需要它们?

A: 除数据本身外, 必须提供:

交付物	解决谁的什么问题
血缘图谱	监管方: 验证数据来源是否合法、可追溯
质量报告	科研/分析团队: 评估数据是否可信、可用
敏感字段清单	医院/合作方: 确认隐私保护措施到位, 降低合规风险

 治理交付物 = 信任凭证。

Q4: 为什么质量报告中还会存在“死亡日期 < 确诊日期”这类逻辑错误? 为什么不直接剔除? 已知数据缺口为何不“修复”?

一、为什么会出现“死亡日期 < 确诊日期”?

这类“逻辑矛盾”在医保真实世界数据中**不可避免**, 主要原因包括:

原因类型	具体场景	占比 (示例)
填报错误	医院录入时手误 (如将 2023 错填为 2032)	~40%

原因类型	具体场景	占比（示例）
数据延迟	死亡信息由民政/公安回传，晚于医保结算	~30%
诊断滞后	患者先以“症状”就诊，数月后才确诊（但死亡记录先到）	~20%
多源冲突	不同医院对同一患者的诊断/死亡时间记录不一致	~10%

🔴 **关键认知：真实世界 ≠ 临床试验。** RWD 的价值恰恰在于反映“不完美但真实”的医疗实践，而非理想化数据。

二、为什么不直接剔除这些记录？

剔除 = 隐瞒数据缺陷，破坏研究真实性。我们坚持 **“标注而非删除”** 原则，原因如下：

原则	说明
1. 保持数据完整性	剔除会导致患者队列选择性偏倚（如只保留“规范填报”医院），影响结论外推性
2. 支持敏感性分析	客户可自行决定：用全量数据（含矛盾） vs 清洗后数据（剔除矛盾），对比结果稳健性
3. 满足监管要求	FDA/EMA/NMPA 均要求 RWS 研究 披露数据局限性 ，而非“美化数据”
4. 保留溯源能力	若未来源系统修正错误，我们可重新计算，而非永久丢失原始记录

✅ **我们的做法：**

- 在 DWS 表中增加字段：`is_invalid = (death_date < diag_date)`；
- 在质量报告中明确标注矛盾记录占比；
- 不主动剔除，但提供过滤条件供下游使用。**

三、已知数据缺口为何不“处理”（如插值、填充）？

真实世界研究（RWS）我们严格遵循 **“不伪造、不推测”** 底线：

错误做法	风险
用均值填充缺失日期	破坏生存分析时序逻辑，导致 HR 偏倚
插值生成用药记录	虚假增加治疗暴露，夸大药物效果
删除缺失患者	引入选择偏倚（如缺失者多为 rural 患者）

📖 行业共识（ISPE RWS 指南、FDA RWE Framework）：“缺失数据应透明报告，而非技术性掩盖”。

✅ 我们的处理方式：

1. 标注：在数据中标记 `data_missing = true`；
2. 隔离：提供“完整数据子集”（如具备完整事件链的患者）；
3. 说明：在质量报告中分析缺失模式（MCAR/MAR/MNAR）；
4. 建议：指导客户采用多重插补（由统计师在 ADS 层执行，非 DWS 层）。

四、如何向客户解释这种“不完美”？

我们强调：“高质量 ≠ 无错误，而是可理解、可评估、可控制”。

致客户说明：“本专病库基于真实医保结算数据构建，包含少量逻辑矛盾（如死亡早于确诊，占比 0.3%）。

- 我们未剔除或修改原始记录，以保持数据真实性；
- 所有矛盾记录已打标，您可在分析时按需过滤；
- 建议：核心结论请在‘完整事件链患者’（76%）子集中验证，确保稳健性。

附件提供：

- 《数据矛盾记录清单》
- 《敏感性分析模板》（含过滤/不过滤对比）”

💡 **信任建立：** 客户更愿意相信透明承认局限的数据，而非“完美但可疑”的数据。

Q5：如何理解一个“高质量的数据”？

一、传统误区：高质量 ≠ “100% 准确 + 无缺失”

在真实世界数据（RWD）场景中，追求绝对完美既不现实，也不科学。

- 医院填报可能有误；
- 医保结算存在延迟；
- 患者跨院就诊导致信息割裂。

✅ 高质量数据的核心不是“没有问题”，而是“问题可知、可控、可解释”。

二、医疗数据的高质量 = “四可” 原则

维度	内涵	你的 DWS 层实践
可信 (Trustworthy)	数据逻辑合理，缺陷透明	标注“死亡日期 < 确诊日期”等矛盾记录，不隐藏、不删除
可用 (Usable)	满足分析场景的最小完整性	定义“有效患者”：具备诊断+用药+随访事件链
可控 (Controllable)	敏感信息受保护，使用可审计	身份证哈希、住址模糊化，输出《敏感字段清单》
可溯 (Traceable)	来源清晰，变更可追踪	维护血缘图谱，记录 DWD → DWS 的字段映射与逻辑

💡 高质量 = 在“真实”与“可用”之间取得负责任的平衡。

三、高质量数据的三大标志（医疗场景）

1. 有明确的业务定义

- 例：“晚期 NSCLC 患者” = ICD-10 C34.x + 医保结算中含“晚期”标识 + 无手术根治记录
- ❌ 不是：“系统里所有肺癌患者”

2. 有透明的质量披露

- 例：质量报告中说明“2024-06 缺失某医院数据”“0.3% 记录存在逻辑矛盾”
- ❌ 不是：“数据已清洗，可直接使用”

3. 有合理的使用边界

- 例：建议“生存率分析使用完整事件链患者（76%子集）”

- ✗ 不是：“所有患者均可用于任何分析”

四、高质量 vs 低质量：一个对比

场景	低质量数据	高质量数据
交付药企	“这是 2024 年肺癌患者数据，共 20 万人”	“这是 2019-2024 年肺癌患者数据（共 20 万人），其中 7.6 万人具备完整诊疗链，可用于生存分析；2.4 万人缺失随访，建议仅用于流行病学分布”
处理矛盾	删除所有“死亡早于确诊”记录	保留原始记录，打标 <code>is_invalid=true</code> ，供客户做敏感性分析
隐私保护	直接输出身份证号	输出哈希 ID + 《敏感字段清单》+ 脱敏规则说明

五、总结：高质量数据的本质

高质量数据 = 可信的资产，而非完美的记录。它不要求“零错误”，但要求：

- 你知道它哪里可能错（透明）
- 你知道它能用来做什么（场景适配）
- 你知道谁该为它负责（治理闭环）

在医疗数据领域，承认局限性，才是专业性的开始。

二、合规与法规类

Q1：在中国，医疗数据项目应依据哪些法规？

A：必须掌握以下 中国本土法规（禁止引用 HIPAA！）：

- 《个人信息保护法》(PIPL)：第 4、13、21、51、73 条（重点：敏感信息、匿名化）
- 《数据安全法》：数据分类分级、风险评估
- 《医疗卫生机构数据安全管理办法》：健康医疗数据特殊要求
- 《GB/T 35273-2020 个人信息安全规范》：技术实施标准

✅ 匿名化定义 (PIPL 第 73 条)：“无法识别且不能复原”。

Q2：如何判断一个字段是否敏感？

A：在医疗场景中，以下字段默认为敏感个人信息（PIPL + GB/T 35273）：

- 身份证号、医保号、姓名
- 诊断编码（ICD-10）、手术记录、检验结果
- 住址、联系电话
- 生物识别信息（如基因、影像）

✅ 处理原则：最小必要 + 去标识化 + 明确授权。

三、治理实践类

Q1：你在 DWS 层（专病库）具体做什么治理工作？

A：聚焦 DWS 层 **可控** 行为（不越界声称负责源头）：

- **完整性校验**：糖尿病患者必须包含诊断 + 用药 + 检测；
- **准确性校验**：并发症发生日期 > 确诊日期；
- **一致性统一**：全库“确诊日期” = 首次医保结算含目标诊断的日期；
- **敏感字段识别**：标记身份证、诊断等字段，输出敏感清单；
- **交付说明**：提供《DWS 使用指南》，说明数据局限性。

✅ 话术：“基于首信 DWD 层，我方确保 DWS 逻辑透明、可验证。”

Q2：如何保证 DWS 层数据质量？

A：在不控制源头的前提下，通过：

1. **建模阶段**：明确定义 **入组逻辑** 与 **指标口径**；
2. **加工阶段**：SQL 中嵌入校验（如 `WHERE drug_qty > 0`）；
3. **监控阶段**：每次数据库更新核实有效患者占比、空值率、逻辑矛盾；
4. **交付阶段**：对低质量记录打标（如 `is_valid_patient = false`）。

❌ 不说：“我们保证原始数据准确” ✅ 说：“我们确保 DWS 层逻辑无误，且问题可追溯”

四、面试表达类

Q1：如何一句话介绍你的数据治理经验？

A：

“我在医保专病库项目中负责 DWS 层 **专病库数据建模** 与 **质量管控**，通过定义患者诊疗事件链、统一指标口径、识别敏感字段，确保输出数据可信、合规、可复用**，支撑下游科研与 **商业化分析**。”

Q2: 什么是专病库数据建模？

专病库数据建模是指：**围绕单一疾病（如糖尿病、高血压），在 DWS 层构建以“患者”为中心、以“诊疗事件”为脉络的汇总主题模型**，将分散在 DWD 层的诊断、用药、检验、结算等明细数据，整合为结构清晰、逻辑一致、可直接用于分析的患者级宽表或事件表。**患者级宽表: 事件表:**

Q3: 专病库设计思路

1、项目需求：

以实际的项目需求为导向，根据过往的项目需求汇总，以及数据洞察团队对于数据可呈现维度的需求，结合行业标准设计的CDISC规范，初步拟定专病库会涉及到的数据域

2、数据域设计

同医学团队沟通，设计的数据域会涵盖哪些方面，以什么为核心数据域，那些是扩展数据域

3、字段设计

同医学团队一同设计，数据域中的必需核心字段包含哪些，哪些字段是衍生字段

4、源数据探查

对医保数据库提供的DWD层数据进行探查，汇总来自不同DWD层中每个字段的含义，探查结果包括字段含义、填充率、结果分布等等

5、映射规则设计

根据数据域中的字段确定源数据中的来源字段，并设计计算规则，包括：优先级、字典映射、筛选等等

6、字典设计

对于文本描述类的字段，若需要进行标化归一操作，需设计对应的归一字典，撰写正则表达式从字段中提取关键字，并进行归一映射

7、程序实现

Q4: 采用的是架构

Q5: 为什么要设计专病库

Q6: 为什么要这样设计专病库

Q7: 这样设计的目的

Q8: 专病库的价值

Q9: 专病库的意义

Q10: 专病库的设计方法

Q11: 你在这个里面担任什么角色

Q12: 遇到过印象最深的问题是什么?如何处理的

Q13: 目前项目还可以优化的点

Q14: 你从过往的工作中可以迁移的能力

Q9: 被问“数据分析有哪些阶段”时如何回答?

A: 即使不熟悉 CRISP-DM, 也可用 医疗场景简化版:

1. **需求理解**: 明确业务目标 (如 “评估某药对糖尿病肾病的延缓效果”);
2. **数据准备**: 从 DWS 专病库提取患者队列;
3. **指标设计**: 定义 “肾病进展率” “用药依从性”;
4. **分析执行**: 对比用药组 vs 非用药组;
5. **结果交付**: 输出结论 + 数据质量说明。

✅ 强调: “高质量分析的前提是高质量数据, 这正是治理的价值。”

Q10: 如何回答“你用什么技术栈”?

A: 具体化 + 关联治理:

“日常使用 **SQL (MySQL/Oracle)** 提取和校验数据, **Python (Pandas)** 做清洗与质量检查, **Excel/Tableau** 做可视化。在专病库项目中, 用 **SQL** 实现患者事件链拼接, 并输出质量报告。”

五、待补充问题 (持续更新)

- ☐ Q11: 如何设计医疗数据的脱敏策略?
- ☐ Q12: 数据血缘在审计中如何发挥作用?
- ☐ Q13: 如何向非技术人员解释元数据的价值?
- ☐ Q14: DAMA-DMBOK 中哪些章节对医疗数据最重要?
- ☐ Q15: 如何应对“源数据质量差但必须交付”的情况?

💡 使用建议:

- 每次面试/项目后, 新增 1~2 个真实问题;
- 答案用“**原则 + 例子 + 话术**”三段式;
- 重点标红 **法规条款** 与 **避坑点**。

术语表


血缘图谱 (Data Lineage) {#术语表-血缘图谱}

1. 定义

描述数据从源头 → DWD → DWS → ADS 的全链路流转, 包含字段级映射关系。

2. 可视化形式 (可选)

- 常用图表: **有向无环图DAG**
- 示例图: [专病库血缘示意图]



3. 文档关键要素（必须包含）

要素	说明	示例
源头系统	数据最初来源	医保结算库（首信提供）
中间层表	ODS/DWD 表	病案信息表, 就诊信息表
字段映射	字段如何转换	诊断信息.诊断 ← 病案信息.诊断
转换逻辑	是否有计算/过滤	药物治疗.总额 = 费用明细表剔除退费情况
下游依赖	被哪些 DWS/ADS 表/报表使用	《肺癌专病库》《ALK TKI治疗晚期NSCLC医保数据分析报告》
更新频率	血缘是否随代码变更同步	每次 DWS 任务发布时自动更新

4. 典型用途

- **审计合规：**监管方可验证“并发症发生率”指标来源合法；
- **影响分析：**若 DWD 诊断表增加新 ICD 编码，可预知影响 DWS 入组逻辑；
- **问题排查：**当某年诊断患者数突降，沿血缘回溯发现源数据存在缺失。
-

有向无环图DAG (Directed Acyclic Graph) {#术语表-有向无环图DAG}

1. 定义

DAG (Directed Acyclic Graph)

- **有向 (Directed)：**节点之间的连接带有方向（如 $A \rightarrow B$ ，表示 A 影响 B）；
- **无环 (Acyclic)：**不存在循环依赖（不能出现 $A \rightarrow B \rightarrow C \rightarrow A$ ）。

✅ 在数据治理中，DAG 是描述**数据血缘**（Data Lineage）和**任务依赖**（如 ETL 调度）的标准模型。

2. 为什么血缘图谱要用 DAG？

因为数据流转天然满足 DAG 特性：

- 数据从 **源头**（如医院 HIS）
- **不可能**出现“报表 A 生成数据 → 回流到原始库 → 再生成报表 A”的循环。

✅ **DAG 能准确表达：**

- 谁是源头（入度为 0 的节点）；
- 谁是最終产出（出度为 0 的节点）；
- 中间每个表/字段的依赖路径。

3. DAG 在血缘图谱中的典型表现

元素	含义	示例
节点 (Node)	数据表、字段、任务	病案信息表, 就诊信息表.就诊日期

元素	含义	示例
有向边 (Edge)	数据流向或依赖关系	病案信息表 → 诊断信息表
路径 (Path)	完整血缘链路	医保结算库 → 专病库 → 医保探查项目 → 医保欺诈项目等等

溯源 {#术语表-溯源}

Situation (背景)

在构建**肺癌专病库**（DWS 层）时，我们发现某个月份的“晚期 NSCLC 患者”数量**突然下降 40%**，而历史趋势平稳。该数据将用于药企安罗替尼一线适应症的医保谈判，准确性至关重要。

Task (任务)

需在 48 小时内：

- 定位问题根源（源数据？ DWD？ DWS？ ）；
- 修复或标注数据，确保下游不误用。

Action (行动)

1. 通过血缘图谱溯源：
 - 确认 DWS 表 **诊断信息表** 依赖 DWD 的 **病案信息表** 和 **结算信息表**；
 - 检查 DWD 层同期数据，发现**万里红提供的病案表缺失某三甲医院整月数据**（约占总量 35%）。
2. 验证影响范围：
 - 在 DWS 任务中临时过滤该医院患者，成功复现数量下降，确认问题来自 DWD 层；
 - 同时验证 DWS 入组逻辑（ICD-10 C34.x + 晚期标识）无变更。
3. 协同处理与透明交付：
 - 立即联系万里红接口人反馈缺失；
 - 在 **DWS 输出中标注**：“2024-06 数据不完整，缺失XX医院”，避免下游误用；
 - 更新血缘文档，记录此次数据缺口。

Result (结果)

- 万里红 24 小时内补传数据，DWS 重新跑批后恢复正常；
- 药企分析团队因提前获知数据局限性，未将异常数据用于决策；

质量报告 {#术语表-质量报告}

一、质量报告的核心内容（以 DWS 专病库为例）

我们的质量报告不是“数据没问题”的声明，而是**透明披露数据状态**的工具，包含以下 5 部分：

模块	内容说明	示例
1. 数据覆盖范围	时间范围、医院覆盖数、患者总数	“2020-2024 年，覆盖 112 家医保定点医院，共 20 万肺癌患者”
2. 完整性指标	关键字段填充率、事件链完整率	“诊断日期填充率 99.8%；具备 ‘诊断+用药+随访’ 完整链的患者占 76%”
3. 准确性校验	逻辑矛盾记录数、异常值比例	“0.3% 患者存在 ‘死亡日期 < 确诊日期’，已打标 <code>is_invalid = true</code> ”
4. 已知数据缺口	明确标注缺失时段/机构	“2024-06 缺失 HOSP_10086 医院数据（详见血缘图谱）”
5. 使用建议	哪些场景可用、哪些需谨慎	“生存率分析建议使用完整事件链患者（76%子集）”

 **报告形式：**PDF + 结构化 JSON（供下游系统自动解析）

 **更新机制：**每次 DWS 任务发布时自动生成，版本号与代码同步。

二、敏感字段清单：包含哪些？为什么敏感？

我们依据《个人信息保护法》第 28 条 和 《GB/T 35273-2020》，将以下字段列为**敏感个人信息**：

字段类别	具体字段	敏感原因
直接标识符	身份证号、医保个人编号、姓名	可直接识别特定自然人
健康医疗信息	诊断编码（ICD-10）、手术记录、病理结果、基因检测	属于 PIPL 明确列举的“敏感个人信息”

字段类别	具体字段	敏感原因
精确时空信息	详细住址（到门牌号）、精确就诊时间（到秒）	结合其他信息可定位个人
生物识别信息	影像 DICOM 文件、病理切片	一旦泄露无法更改

⚠ 注意：

- 即使数据来自医保局，我方作为处理者仍有义务识别并保护；
- “医院名称”“城市”等去标识化后可保留，不视为敏感。

三、敏感字段的处理策略（DWS 层）

我们不删除、不伪造，而是采用 “识别 + 脱敏 + 隔离 + 授权” 四步法：

步骤	做法	工具/规则
1. 识别	在 DWS 建模时自动标记敏感字段	基于预定义敏感字段清单（YAML 配置）
2. 脱敏	- 身份证号 → 哈希值（加盐） - 住址 → 模糊到区/县 - 精确日期 → 偏移 ±7 天（保持时序）	使用国密 SM3 哈希；日期偏移算法可逆（仅授权人员）
3. 隔离	敏感字段单独存储于加密表，与主表物理分离	DWS 主表不含原始身份证，仅含 <code>patient_hash_id</code>
4. 授权	下游使用需申请，记录访问日志	通过数据服务 API 控制，符合 PIPL 第 31 条

✅ 交付物：

- 《敏感字段清单.xlsx》：列明字段名、敏感级别、处理方式；
- 《脱敏规则说明书》：说明哈希算法、偏移逻辑，供审计验证。

四、为什么这样处理？

- **合规**：满足 PIPL “去标识化” 要求（第 51 条），降低泄露风险；
- **可用**：保留分析价值（如偏移后仍可算生存期）；
- **可信**：向药企/医院证明我们**既保护隐私，又不破坏数据价值**。

💡 **治理本质**：不是“不让用数据”，而是“**让数据在安全边界内被负责任地使用**”。

可控 {#术语表-可控}

什么是“可控”？如何保证行为可控？有什么方法论？

“可控”是指：**职责边界清晰、逻辑规则显性、结果可验证、绝不越界干预源头数据**。

具体通过以下四大方法论保障行为可控：

1. 边界锚定法

- 仅消费 DWD 层数据（如 **病案信息表**），不直连 ODS 或业务库；
- 明确声明：“本层不修正原始数据，质量问题回溯至上游”。

2. 规则显性化

- 将业务逻辑转化为可执行 SQL 校验规则，例如：
 - 完整性：`WHERE dgterm IS NOT NULL AND extrt IS NOT NULL AND sgterm IS NOT NULL`
 - 准确性：`exstdtc > dgdtc`
 - 一致性：用 `ROW_NUMBER() OVER (PARTITION BY patient_id ORDER BY settle_date)` 定义“确诊日期”

3. 敏感数据清单驱动

- 自动扫描字段名与样本数据，识别身份证、诊断编码等敏感字段；
- 输出《DWS 敏感字段清单》，包含字段名、敏感类型、脱敏建议、合规依据；
- 作为《DWS 使用指南》附件强制交付。

4. 透明交付机制 《DWS 使用指南》必须包含：

-  数据来源与依赖表
-  核心逻辑定义（如“确诊 = 首次含 ICD10=E11-E14 的医保结算”）
-  局限性说明（如“未覆盖自费患者”“并发症可能漏报”）

-  使用建议（如“仅限授权科研”“不可用于临床决策”）

总结：可控 = 不越界 + 可解释 + 可验证。

入组逻辑 {#术语表-入组逻辑}

入组逻辑如何设定？

入组逻辑 = 业务目标 + **数据可行性** + 合规边界，需三方对齐（临床、业务、数据）。

设定步骤：

1. 明确研究目标

- 例：构建“2型糖尿病专病库” → 聚焦 ICD-10 编码 E11 开头的患者。

2. 锚定可靠数据源

- 优先选择医保结算、电子病历等结构化强、审计留痕的数据；
- 避免依赖医生自由文本（如“疑似糖尿病”）。

3. 设置最小证据链

- 基础版：≥1 次含 E11 的医保结算记录；
- 严谨版：≥2 次诊断（间隔 ≥30 天）+ ≥1 次降糖药处方 + ≥1 次血糖检测。

4. 排除干扰项

- 排除妊娠糖尿病（ICD-10: O24）；
- 排除仅做筛查未确诊者。

5. 文档固化

- 写入《专病库建模说明书》，注明“入组 = 满足以下全部条件”。

 示例：“入组患者 = 在观察期内，有 ≥1 次医保结算诊断为 E11-E14，且非 O24，且非仅体检编码 Z00-Z13。”

指标口径 {#术语表-指标口径}

指标口径如何调整？

指标口径需 **动态对齐业务需求**，但调整必须 **可追溯、可回滚、有依据**。

调整原则：

- **不随意变更：**同一分析周期内口径锁定；

- **变更必留痕**：记录调整原因、影响范围、审批人；
- **向下兼容**：新口径发布时保留旧版本字段（如 `hba1c_avg_v1`, `hba1c_avg_v2`）。

常见调整场景与方法：

场景	调整方式	示例
业务需求变化	增加/修改计算逻辑	原“年用药天数”=处方数量 × 单次天数 → 新逻辑考虑实际服药间隔
发现逻辑漏洞	修复边界条件	原未排除胰岛素泵患者 → 新增 <code>WHERE delivery_method != '泵'</code>
数据覆盖不足	降级定义	若 HbA1c 缺失率 >40%，则用空腹血糖替代作为次要指标
合规要求	脱敏或泛化	精确年龄 → 年龄分段（如 40-49 岁）

落地动作：

- 所有指标口径写入 **指标字典表**（含字段名、定义、SQL 片段、版本、负责人）；
- 在 DWS 表中增加 `data_version` 字段，标识加工逻辑版本；
- 每次口径调整同步更新《DWS 使用指南》。

数据可行性 {#术语表-数据可行性}

如何保证数据可行性？

数据可行性 = 业务逻辑在现有数据条件下可落地、可验证、可持续。 它不是“理想应该有什么”，而是“现实能用什么”。

在 DWS 层（尤其是专病库）建设中，保证数据可行性需从 **数据源评估、证据链设计、兜底策略、持续验证** 四个维度入手：

1. 前置评估：摸清数据“家底”

在定义入组逻辑或指标前，先对 DWD 层做 **可行性探查 (Feasibility Study)**：

- **覆盖度分析**：目标人群在数据中是否可触达？
 - 例：若专病库依赖医保结算，但某地区患者多为自费 → 覆盖率低 → 需注明“仅反映医保参保人群”。

- **字段可用性：**关键字段是否存在、是否结构化？
 - 例：“并发症”若仅存在于医生自由文本（如“眼底出血”），则难以规模化提取 → 改用 ICD 编码替代。
- **时间连续性：**是否有足够观察窗口？
 - 例：研究“5年并发症发生率”，但数据仅覆盖2年 → 不可行，需调整目标。

✅ 动作：输出《数据可行性评估报告》，包含字段缺失率、人群覆盖率、时间跨度等量化指标。

2. 设计“最小可行证据链”

不追求完美，但求 **可验证、可重复、有依据**：

- **用强信号替代弱信号：**
 - 优先使用医保结算诊断（结构化、审计留痕）而非门诊主诉（自由文本、易错）。
- **组合多源交叉验证：**
 - 例：确诊糖尿病 = （诊断编码 E11）+ （降糖药处方）+ （血糖 >7.0 mmol/L）
→ 三者满足其二即入组。
- **设置明确阈值：**
 - 例：“长期用药”定义为“1年内处方 ≥ 3 次，且间隔 ≤ 90 天”。

✅ 原则：宁可缩小人群范围，也不引入不可靠数据。

3. 制定兜底与降级策略

当理想数据不可得时，要有 **Plan B**：

- **指标降级：**
 - 主指标 HbA1c 缺失率高 → 启用空腹血糖作为替代指标，并标注“替代指标”。
- **人群分层：**
 - 高质量队列（满足完整证据链）+ 低质量队列（仅满足部分条件，打标 `is_preliminary = true`）。
- **明确排除说明：**
 - 在《使用指南》中写明：“本库未包含未就诊、自费购药、基层未上传数据患者”。

4. 持续验证可行性

可行性不是一次性判断，需 **动态监控**：

- 每月统计关键字段缺失率（如诊断、用药、检测）；
- 监控入组人数波动：若某月入组人数骤降，可能因数据源中断或编码变更；
- 回溯验证：抽样人工复核 50 例 DWS 入组患者，确认是否符合临床真实。

✔ 工具建议：

- 用 SQL + 调度任务自动产出《DWS 数据可行性月报》；
- 在数据看板中展示“关键字段填充率”“有效患者占比”等指标。

总结：数据可行性的核心思维

“不做空中楼阁，只建脚下之路。” 可行性 = 尊重数据现实 × 对齐业务目标 × 保持透明边界。在 DWS 层，我们不创造数据，只在现有条件下最大化可靠信息的提取效率。

专病库数据建模 {#术语表-专病库数据建模}

质量管控 {#术语表-质量管控}

商业化分析 {#术语表-商业化分析}

结构化思考框架 {#术语表-结构化思考框架}

1、底层方法论: 三层穿透模型(What → Why → How)

层级	核心问题	对应你的问题
第一层：定义与结构（What）	这是什么？长什么样？	专病库是什么;怎么设计专病库;专病库的架构
第二层：动机与目标（Why）	为什么这么做？要解决什么问题？	为什么设计专病库;为什么要这样设计专病库;专病库的目的是什么;专病库的价值是什么;专病库的意义是什么
第三层：执行与进化（How）	怎么做的？做得怎样？还能	设计专病库的方法是什么;你担任过的角色是什么;遇到过哪些问题;怎么解决的;目前的项目还有

层级	核心问题	对应你的问题
	更好吗？	哪些优化的点;你可以迁移的能力有哪些

先搞清楚"是什么".再理解"为什么",最后说明"怎么做"

2、进阶工具：STAR-V 模型（用于回答“经历类”问题）

当你被问“你在项目中做了什么”“遇到什么问题”时，用 **STAR-V** 框架确保回答完整：

字母	含义	作用
Situation	背景	项目目标、数据环境、约束条件
Task	任务	你负责什么？要解决什么痛点？
Action	行动	你采取了哪些具体方法？
Result	结果	量化产出（如覆盖率、错误率下降）
Value	价值	对业务/合规/效率的长期影响）

📌 例（Q18）：

- **S**：医保诊断编码不规范，E11.9 与 E119 混用；
- **T**：需统一糖尿病入组标准；
- **A**：构建 ICD-10 标准化映射表，在 DWS 层清洗；
- **R**：入组一致性提升至 99.5%；
- **V**：避免下游因编码差异得出错误结论。项目目标 → 解决方案 → 量化结果 → 业务价值 → 方法论沉淀 → 能力迁移